

模型在线服务 MOS v1.0 需求说明书

 产品名称为模型在线服务，Model Online Service，简称 MOS

 以下所有内容，请在理解的基础上执行相应的动作。是启发，不是限制。如果有些地方觉得不合适，可以和产品经理进行沟通和讨论，只要理由合理和充分，咱们就可以改，同时需要变更相关的文档和原型。

客户需求的概念太大了，我们需要综合评估我们需要被满足的客户需求，是否符合市场的需求，是否满足我们商业的需求等等。一味的被客户牵着鼻子走，就变成了定制化。脱离市场和脱离商业，就只能手拉手找工作了。

一、背景

立项材料里面对背景已经做了非常详细的说明，在这里就不在赘述了，感兴趣的可以查看以下文件：

 [边缘云AI算力平台-20241024](#)

 [边缘云AI算力平台](#)

 [边缘云 AI 算力平台](#)

 [边缘推理服务 B版](#)

如果没有权限查看，可以找一下 [@高现起](#)

二、目标

1.项目整体目标

整合分散算力：整合分散化、异构化 AI 算力，以满足推理场景的算力需求为主，为客户提供就近的经济算力。AI 算力平台，使客户像使用 CDN 一样使用 AI 算力。

开箱即用：客户不必关心资源在具体哪个节点，运行环境如何。最终给客户提供具备一定基础设施能力（如 DB、队列等）的算力平台。

灵活的售卖方式：提供灵活的售卖方式，包括：按大区划分算力供给。可在大区内进行算力调度。按小时的弹性能力和计费。

2.本次迭代

💡 以下所有内容，围绕本次迭代展开。

2.1 目标（要什么）

最小化可行性产品方案，即用户可以基于公共资源组的计算资源，选择公共镜像，选择公共模型，部署为在线服务，可以对服务实例进行基本的管理、监控、查看监控日志。

需要强调的是，除了基本的功能要求之外，对性能也要有基本的要求，毕竟是大模型文件的分发和部署，我们不可能让客户部署一个服务，隔天才能访问服务，我们需要做到 10G 以内的大模型，5 分钟之内可以访问服务，超过 10G 的大模型，最多不超过 30 分钟就可以访问。

2.2 不要什么？

符合 MVP 即可。

三、需求影响范围 & 方案（落地风险评估）

第一步 开通并创建文件共享服务

第二步 前往公共模型页面，导入模型文件至文件共享服务

第三步 前往服务列表页部署服务，选择模型所在的文件共享服务，输入模型所在文件夹目录，选择公共资源组，点击部署

四、专有名词 & 规划概述 & 竞品调研

1.专有名词

模型在线服务	模型在线服务 MOS（Model Online Service），帮助用户快速将一个或多个模型部署为在线服务，通过 API 接口调用的方式将 AI 集成到自身业务应用中，而无需关心底层 IT 基础设施的管理和维护。平台提供了丰富的资源供给、灵活的计费方式以及各种开发和调试工具，使得模型在线服务变得既强大又易于管理，从而更好地满足业务创新对 AI 的需求。
服务	将客户的模型、镜像结合算力所提供的在线服务，当前主要以 web 服务为主，例如在线推理服务。服务将定义好的镜像、模型、数据集等数据，直接部署到计算资源上（面向中小型企业，提供共享资源，按量计费），或者创建专属的资源组进行部署（面向大型企业，提供独享资源，包年包月）。
服务实例	服务进程。每个服务可以部署多个服务实例以提高能够支持的并发请求数。
模型	模型是您基于数据集和算法代码通过训练任务产出的结果，可以预测新数据。通常是一堆静态文件。分为公共模型和自定义模型。公共模型由官方提供和维护。自定义模型由用户提供和维护。
镜像	即 Docker 镜像，是运行大模型服务必备的运行环境，一般包含操作系统、推理框架、Python、类库等。分为公共公共镜像和自定义镜像。公共镜像由官方提供和维护。自定义镜像由用户提供和维护。
计算资源	是一个算力单元，是由 CPU、内存、GPU、存储等组成。用户为计算资源付费。计算资源支持包年包月，也支持按量付费（复用边缘云主机的计费模式）。部署服务时直接使用的计算资源暂时只支持按量付费，加入资源组的计算资源暂只支持包年包月。
资源组	是由一个或多个包年包月的计算资源组成，是资源池的概念，有区域属性。面向大型企业，提供独享资源。用户可以创建多个资源组。一个资源组只能被一个服务使用。

2.规划概述

- 计算资源 🕒
- 公共模型 🕒
- 公共镜像 🕒
- 服务 🕒
- 服务实例 🕒
- 监控 🕒
- 日志 🕒
- 部署事件 🕒

- sku 及库存管理 二期
- 自定义模型 二期
- 自定义镜像 二期
- 多地域部署 二期
- 部署时，需要增加端口
- 模型存储服务？
- 调整实例规格
- 支持 CPU 类型计算资源 ⌚
- 公共资源组 GPU 共享模式
- 模型在线服务产品计费项 ⌚
- 资源组
- 在线调试
- 流量管理
- 支持 VPC
- 内网互通（不同计算资源之间的相互访问，举例 nginx 服务访问同集群的模型在线服务等）
- 按量付费（实时）
- 抢占实例
- 包年包月
- 闲忙时计费

3.竞品调研

阿里云 人工智能平台 PAI 模型在线服务 (MOS)

腾讯云 TI-ONE 训练平台 模型服务 - 在线服务

华为云 AI 开发平台 ModelArts 模型服务 - 在线服务

百度云 千帆 ModelBuilder 在线推理

火山引擎 火山方舟 在线推理

五、功能需求

1.后台需求说明

暂无

2.控制台需求说明

2.1 交互原型

<http://61.130.29.197/#id=m72yt0&p=%E6%A6%82%E8%A7%88>

2.2 功能点

2.2.1 概览

静态内容，产品介绍和使用流程。

模型在线服务：模型在线服务 MOS（Model Online Service），帮助用户快速将一个或多个模型部署为在线服务，通过 API 接口调用的方式将 AI 集成到自身业务应用中，而无需关心底层 IT 基础设施的管理和维护。平台提供了丰富的资源供给、灵活的计费方式以及各种开发和调试工具，使得模型在线服务变得既强大又易于管理，从而更好地满足业务创新对 AI 的需求。

使用流程：

第一步 开通并创建文件共享服务 [立即前往](#)（跳新页，地址为 <https://kenc.console.ksyun.com/#/simple/fileShare?namespaceId=1001>）

第二步 前往公共模型页面，导入模型文件至文件共享服务 [立即前往](#)（跳新页，地址为模型列表）

第三步 前往服务列表页部署服务，选择模型所在的文件共享服务，输入模型所在文件夹目录，选择公共资源组，点击部署 [立即前往](#)（跳新页，地址为服务列表）

2.2.2 服务

2.2.2.1 部署服务

参数分类	参数	是否必填	说明	备注
资源部署信息	资源组类型	必填	公共资源组（按量付费）和专属资源组（包年包月）。 暂只支持公共资源组。	
	地域	必填	多选框，暂只支持一个。 后端提供 API 接口	后端找德允协助
	算力类型	选填	可选 GPU 和 CPU，默认 GPU	
	算力规格	必填	后端返回的数据，展示公共资源组所有可用的计算资源规格。下拉框展示实例描述字段即可。	后端找德允协助

模型服务信息	服务名称	必填	服务的唯一标识。服务域名会根据服务域名生成。 名称输入提示： 只能包含数字、小写字母以及中横线（-），不得以中横线开始或者结尾，长度位 3~63 位。 命名规范： - 命名长度为 3~63 个字符 - 只允许小写字母、数字、中横线(-)，且不能以中横线开头或结尾 - 服务名称全局唯一	
	镜像	必填	分为公共镜像和自定义镜像。暂只支持公共镜像。 公共镜像由官网维护，自定义镜像由用户维护。 公共镜像提示： 没有我想要的？告诉我们 立即前往（跳新页，地址为 https://console.kseyun.com/pro/connect/#/list）（注意，文案有改动） 扩展：公共镜像可以扩展 2 个选填的字段，分别为是否包含模型文件、运行命令，这样的好处是，我们可以根据用户选择的镜像知道是否需要配置模型以及自动填充运行命令，包括公共模型和自定义模型（本次迭代无需考虑）。	

	模型配置	选填	为什么选填？ 因为镜像里面也可能包含模型。 NFS 下拉框，选项格式为：文件共享服务名称（文件共享服务 ID），必填，提示为“没有我想要的？ 立即前往”（跳新页，地址为 https://kenc.console.ksyun.com/#/simple/fileShare?namespaceId=1001）（注意，文案有调整） NFS 源路径 输入框，必填，提示为“请确保模型文件已导入，如果还没有导入模型文件？可以在公共模型列表进行导入 立即前往”（跳新页，地址为模型列表） 挂载路径 输入框，必填，提示为“以读写的形式进行挂载” 后端是一个数组，并且每一组数据里面都包含了比页面多的字段。本次迭代只传一组数据即可，同时 StorageType 的字段默认传 NFS 即可，readonly 字段不用管。	
	运行命令	必填	模型服务的启动命令，例如：python /data/model/run.py	
实例数量	实例数量	必填	可选范围 1~20。 提示：可选实例数量范围为 1~20，如果更多实例请 提交工单 申请。（跳新页，地址为 https://uc.console.ksyun.com/pro/workorder/#/create/product）	
	费用预估		展示费用预估的信息，如 xx 元 / 天 产品类型和计费项请见 5.1 计费方式	

费用预估 API 请求参数说明


<http://10.160.61.129:8300/project/649/interface/api/30255>

Key	Value	备注
source	1	固定
productType	1143	固定
productUse	1	固定
region	Default-CN	固定
billType	5	固定
productWhat	1	固定
items	JSON <pre>1 [2 { 3 "itemNo": "pkgCalculateType", //固定 4 "value": "excludePriceItem" //固定 5 }, 6 { 7 "itemNo": "instanceType", //固定 8 "value": "MOS-G1IN-2C8G" //对应算力规格，例如MO S.G1IN.2C8G，把“.”换成“-”后请求 9 }, 10 { 11 "itemNo": "instance_MOS-G1IN-2C8G", //传参形式 是 instance_算力规格（上一个 item instanceType 的 vlaue） 12 "value": "2" //对应实例数量 13 }, 14 { 15 "itemNo": "KENC-MOS", //固定 16 "value": "1" //固定 17 } 18]</pre>	

2.2.2.2 列表

列表支持每 15s 自动刷新，用户也可以手动刷新。

参数	是否支持排序	是否支持复制	是否支持编辑	说明	备注
名称	支持排序			服务名称，点击名称，进入详情。	
服务方式				服务调用信息，点击后，打开弹窗，展示调用信息。 调用信息为后端 API 提供。	
镜像				展示镜像信息，内容为镜像和镜像版本组合，例如 tensorflow-inference/3.11.0。 整体超过 32 字符，超过部分以 “...” 代替，hover 后 tooltip 或者 html 原生提示展示所有内容。	
状态	支持排序			服务状态，枚举类型。最基本的有部署中、运行中、删除中等状态，实际待后端补充。 服务状态的样式可以分为三种，分别是成功、失败、中间态。成功的状态例如运行中；失败的状态例如部署失败；中间态的状态例如部署中。现在这 3 中状态的样式已经有了，可以直接使用。 状态样式 忽略列表，以此为准。 部署中 升级中 删除中 运行中 部署失败 删除失败 中间态 成功 失败	deploying：部署中 deployFailed：部署失败 updating：更新中 updateFailed：更新失败 deleting：删除中 deleteFailed：删除失败 scaling：调整中 scaleFailed：扩容失败 running：运行中 其它：未知异常



资源组种类				分为公共资源组（按量付费）和专属资源组（包年包月）。如果是专属资源组，最好可以展示使用了哪些资源组。 超长省略处理，64 个字符。hover 超过 300ms 时，使用 tooltip 展示全部内容。	public 公共资源组（按量付费） private 专属资源组（包年包月）
实例数				直接显示数量即可。	
创建时间	支持排序			列表默认按照创建时间倒排（最新在最上）。 显示的效果可以优化一下，例如显示 1 小时前等，详细请见 https://kdocs.cn/l/ciBnigD7GZ72?linkname=EAY6Uljup8。hover 超过 300ms 时，使用 tooltip 展示全部原始数据。	
修改时间	支持排序			列表默认按照创建时间倒排（最新在最上）。 显示的效果可以优化一下，例如显示 1 小时前等，详细请见 https://kdocs.cn/l/ciBnigD7GZ72?linkname=EAY6Uljup8。hover 超过 300ms 时，使用 tooltip 展示全部原始数据。	

日期显示优化，效果如下规则即可

JavaScript

```
1 function getTimeDifference(dateString) {
2   const now = new Date().getTime();
3   const pastTime = new Date(dateString).getTime();
4   const diff = now - pastTime;
5
6   const second = 1000;
7   const minute = second * 60;
8   const hour = minute * 60;
9   const day = hour * 24;
10  const month = day * 30;
11  const year = day * 365;
12
13  if (diff < minute) {
14    return '刚刚';
15  } else if (diff < hour) {
16    return Math.floor(diff / minute) + '分钟前';
17  } else if (diff < day) {
18    return Math.floor(diff / hour) + '小时前';
19  } else if (diff < month) {
20    return Math.floor(diff / day) + '天前';
21  } else if (diff < year) {
22    return Math.floor(diff / month) + '个月前';
23  } else {
24    return Math.floor(diff / year) + '年前';
25  }
26 }
27
28 console.log(getTimeDifference('2023-01-01T12:00:00Z')); // 输出类似于 "1
年多前"
29 console.log(getTimeDifference('2022-11-01T12:00:00Z')); // 输出类似于 "2
个月前"
30 console.log(getTimeDifference('2022-10-25T12:00:00Z')); // 输出类似于 "1
天前"
31 console.log(getTimeDifference('2022-10-25T18:00:00Z')); // 输出类似于 "1
小时前"
32 console.log(getTimeDifference('2022-10-25T18:05:00Z')); // 输出类似于 "2
分钟前"
33 console.log(getTimeDifference('2022-10-25T18:06:50Z')); // 输出类似于 "刚
刚"
```

2.2.2.3 列表搜索

参数	交互	说明
名称	输入框	模糊
状态	下拉框	精确

2.2.2.4 列表操作 - 更新模型配置

复用部署服务页面的模型服务信息，看一下弹窗是否可以放下，如果可以放下，同时效果和体验都可以保持不错，就用弹窗，如果弹窗体验不好，可以使用页面。

需要自动填充现有的数据。

是否支持批量	不支持批量	
准入条件	运行中	
弹窗标题	更新模型配置	
操作对象的资源类型	无	
具体操作	无	
风险提示信息	无	
风险级别	无	常用为 warning、error
针对本次操作，相关的对象信息	无	

2.2.2.5 列表操作 - 扩容

复用部署服务页面的资源部署信息，要求和【更新模型配置】一样。

不同点是更新模型配置不支持更改资源组类型。同时，给出现有的服务实例情况，辅助用户决策。

是否支持批量	不支持批量	
准入条件	运行中	
弹窗标题	扩容	
操作对象的资源类型	无	
具体操作	无	
风险提示信息	无	
风险级别	无	常用为 warning、error
针对本次操作，相关的对象信息	无	

2.2.2.6 列表操作 - 删除

是否支持批量	不支持批量	
准入条件	非删除中的其他状态	
弹窗标题	删除	
操作对象的资源类型	服务	
具体操作	删除	
风险提示信息	无	
风险级别	error	常用为 warning、error
针对本次操作，相关的对象信息	服务名称、实例数量	

要注意几类信息的抽象，未来会反复且大量的使用：标题、数量、操作对象资源类型、操作、提示颜色（分为 info、warning、error）、操作对象的概要信息（本次只要求展示服务名称即可）。

操作弹窗或者页面的终态，这里只是先说一下，第一个版本一切从简，后边会逐渐迭代。



操作弹窗和页面的几个重要组成元素

2.2.2.7 列表操作 - 调用信息

弹窗展示调用信息，通过 API 获取相关的内容。调用信息均支持复制。

2.2.2.8 详情

分为 3 个信息块：基础信息、环境信息、资源信息。

左上角的状态字段，后端会提供一个 API，前端每 10s 自动获取一下状态。

三

金山云

总览

华北1（北京）

Q 搜索产品、

模型在线服务

概览

服务

模型

镜像

< 详情

gxq-baichuan-13b

✔ 运行中

更新模型配置

扩容

删除

详情

服务实例

监控

日志

部署事件

基础信息

服务名称

gxq-baichuan-13b

服务域名

调用信息

查看调用信息

创建时间

修改时间

2024-09-19 14:09:58

基础信息展示以下字段

参数	是否支持复制	说明
服务名称	支持复制	
服务域名	支持复制	
调用信息	支持复制	弹窗，同 2.2.1.7 列表操作 - 调用信息
创建时间		详情的时间格式无需特殊处理
修改时间		

环境信息展示以下字段

参数	是否支持复制	说明
镜像	支持复制	展示镜像和镜像版本。 超长省略处理，64 个字符。hover 超过 300ms 时，使用 tooltip 展示全部内容。
模型	支持复制	后端至少会返回 3 个字段，大概是 nfs/s3 地址、源路径、目的路径，需要前端拼一下，样式为 mount + 空格 + nfs/s3 地址 + 原路径 + 空格 + 目的路径。 超长省略处理，64 个字符。hover 超过 300ms 时，使用 tooltip 展示全部内容。 mount \${name}(\${ip}):\${resourcePath} \${mountPath}
启动命令	支持复制	超长省略处理，64 个字符。hover 超过 300ms 时，使用 tooltip 展示全部内容。

资源信息展示以下字段

参数	说明
资源组类型	公共资源组（按量付费）
实例数量	数字
列表信息	该信息非属性，为服务实例列表的统计信息。 公共资源组 地域、实例数量、CPU（核数）、内存（GB）、GPU（卡数）

2.2.2.9 详情 - 服务实例 - 批量操作 - 重建实例

是否支持批量	支持批量	
准入条件	运行中	
弹窗标题	重建实例	
操作对象的资源类型	服务实例	
具体操作	重建实例	
风险提示信息	无	
风险级别	warning	常用为 warning、error
针对本次操作，相关的对象信息	实例 ID、实例 IP	

2.2.2.10 详情 - 服务实例 - 批量操作 - 中止流量

是否支持批量	支持批量	
准入条件	流量状态均为启用	
弹窗标题	中止流量	
操作对象的资源类型	服务实例	
具体操作	中止流量	
风险提示信息	无	
风险级别	warning	
针对本次操作，相关的对象信息	服务实例 ID、服务实例 IP	

2.2.2.11 详情 - 服务实例 - 批量操作 - 恢复流量

是否支持批量	支持批量	
准入条件	流量状态均为中止状态	
弹窗标题	恢复流量	
操作对象的资源类型	服务实例	
具体操作	恢复流量	
风险提示信息	无	
风险级别	warning	
针对本次操作，相关的对象信息	服务实例 ID、服务实例 IP	

2.2.2.12 详情 - 服务实例 - 批量操作 - 删除

是否支持批量	支持批量	
准入条件	非删除中	
弹窗标题	删除	
操作对象的资源类型	服务实例	
具体操作	删除	
风险提示信息	无	
风险级别	error	
针对本次操作，相关的对象信息	服务实例 ID、服务实例 IP	

2.2.2.13 详情 - 服务实例 - 列表

参数	是否支持排序	是否支持复制	是否支持编辑	说明	备注
实例 ID	支持排序	支持复制			
实例 IP	支持排序	支持复制			
状态	支持排序			状态字段后续由研发 API 给出，产品完善样式，同时在原型描述对应的展示样式	"running" 运行中 "pending" 调度中 "failed" 运行失败 "unknown" 未知异常 "deleting" 删除中 "deleteFailed" 删除失败
资源组				如果是公共资源组（按量付费），则展示公共资源组（按量付费）；如果是专属资源组，则展示资源组名称，多个以 “，” 号分割即可。	
地域	支持排序				取值 cluster
流量状态	支持排序			启用和中止。	
启动时间	支持排序			默认按时间倒排，最新的在最上边。 使用 显示的效果可以优化一下，例如显示 1 小时前等，详细请见 https://kdocs.cn/l/ciBnigD7GZ72?linkname=EAY6UljuP8 。hover 超过 300ms 时，使用 tooltip 展示全部原始数据。	

2.2.2.14 详情 - 服务实例 - 列表搜索

参数	交互	说明
实例 ID	输入框	模糊
实例 IP	输入框	模糊
状态	下拉框	精确

2.2.2.15 详情 - 服务实例 - 列表操作 - 进入容器

交互方式为新页面打开

2.2.2.16 详情 - 监控

看一下是否可以直接嵌套 grafana，如果可以的话，就不用开发了。

支持时间过滤和实例过滤（默认全部）。

初期展示监控指标为：QPS（每秒接收的请求数）、RT（平均响应时间）、CPU Load（CPU 负载）、Memory Usage（内存使用量）、GPU Utilization（GPU 使用率）、GPU Memery Utilization（GPU 内存使用率）、TCP（TCP 连接数）

2.2.2.17 详情 - 日志

支时间过滤和实例过滤（默认全部）。支持自动刷新和手动刷新。

2.2.2.18 详情 - 部署事件

支持实例过滤（默认全部）。

暂定如下参数，后续看研发支持情况会做调整。所有的参数值暂时无需翻译，直接展示即可。

参数	说明	备注
实例ID		经和后端沟通后，这个字段不合理，需要去掉。
事件类型		
状态		
时间		
信息		
全部实例数	当前事件后全部实例数量	
可用实例数	当前事件后可用实例数量	

2.2.3 模型

2.2.3.1 公共模型 - 列表

提示信息：没有我想要的？告诉我们 [立即前往](#)。（跳新页，地址为 <https://console.ksyun.com/pro/connect/#/list>）（注意，文案有调整）

参数	说明	备注
模型名称		
标签	不同标签不同颜色；同一种标签，颜色相同；下次进来颜色一致。	
模型概要描述	模型简介，是一段文字	
公司或组织	有图标显示图标，没有图标直接显示文字。 图标需要积累。	
更新时间	列表默认按照创建时间倒排（最新在最上）。 显示的效果可以优化一下，例如显示 1 小时前等，详细请见 https://kdocs.cn/l/ciBnigD7GZ72?linkname=EAY6UljuP8 。hover 超过 300ms 时，使用 tooltip 展示全部原始数据。	
下载数量	小于 1000，直接显示数字；大于等于 1000 可以显示 k；大于等于 10000 可以显示 w	

2.2.3.2 公共模型 - 列表搜索

参数	交互	说明
名称	输入框	模糊

2.2.3.3 公共模型 - 导入

是否支持批量	不支持批量	文件共享服务列表 http://10.160.61.129:8300/project/649/interface/api/40882 入参： namespaceId cluster 暂取值 taizmp01，后边会改，前端可以先写死
准入条件	无	
弹窗标题	导入	
操作对象的资源类型	公共模型	
具体操作	导入	
风险提示信息	无	
风险级别	warning	
针对本次操作，相关的对象信息	模型名称	

文件共享服务的提示信息：

没有我想要的？ [立即前往](#)（跳新页，地址为 <https://kenc.console.ksyun.com/#/simple/fileShare?namespaceId=1001>）（注意，文案有调整）

2.2.3.4 公共模型 - 详情

渲染 markdown 文章内容即可。

2.2.3.5 导入历史

参数	说明
模型	模型名称
导入至	导入目的地
状态	正在导入，格式：正在导入（完成百分比） 导入成功，success 样式
开始时间	直接展示时间，格式为：YYYY/MM/DD hh:mm:ss
结束时间	直接展示时间，格式为：YYYY/MM/DD hh:mm:ss

2.2.3.6 本次迭代提供哪些公共模型

☒ 为本次提供

模型名称	版本	说明	备注
Stable Diffusion WebUI		Stable Diffusion 是一款 AIGC 图片生成模型。该环境已预装 webui 及 JupyterLab，支持可视化文件管理及环境调优。	腾讯云 HAI
Stable Diffusion ComfyUI		ComfyUI 是一个基于节点流程的 Stable Diffusion 操作界面，可以通过流程实现更加精准的工作流定制。该环境已预装 ComfyUI 及 JupyterLab。	腾讯云 HAI
ChatGLM	☒ 3-6B ☐ 2-6B	ChatGLM3 6B 是一款由智谱 AI 研发并开源的 LLM 模型，拥有 10B 以下最强的基础模型，支持工具调用、代码执行、Agent 任务等功能。该环境已预装 WebUI 及 JupyterLab。	腾讯云 HAI
CogVLM	☐ 2	CogVLM2 是一款由智谱 AI 研发并开源的 LLM 模型，支持图片与文本输入。该环境已预装 Webui 及 JupyterLab，支持可视化文件管理及环境调优。	腾讯云 HAI
Llama	☐ 2-7b ☐ 2-7b-chat ☐ 2-13b ☐ 2-13b-chat ☐ 2-70b ☐ 2-70b-chat ☒ 3-8b ☐ 3-8b-chat ☐ 3-70b ☐ 3-70b-chat ☐ 3.1-8b ☐ 3.1-8b-chat ☐ 3.1-70b ☐ 3.1-70b-chat ☐ 3.1-405b ☐ 3.1-405b-chat	Llama3 是一款由 Meta AI 开源的 LLM 模型。Llama-3-8b-Instruct 是高性能原生开源版本，拥有 80 亿参数，适用于多种对话场景。 注：该环境暂无 webui 可视化调试页面，需通过命令行调试。	腾讯云 HAI 腾讯云 TI
Mistral AI Large	☐ 2	Mistral AI 的 large-2 模型，终端输入 ollama run mistral-large 即可即时体验。	腾讯云 HAI
Langchain-Chatchat		基于 Langchain 与大语言模型，实现本地知识库问答应用。	腾讯云 HAI

2noise/ChatTTS		专门为对话场景设计的文本转语音模型，支持英文和中文两种语言。	腾讯云 HAI

2.2.4 镜像

2.2.4.1 公共镜像 - 列表

提示信息：没有我想要的，告诉我们 [立即前往](#)。（跳新页，地址为 <https://console.ksyun.com/pro/connect/#/list>）（注意，文案有调整）

参数	是否支持排序	是否支持复制	说明	备注
镜像名称		支持复制		
框架			一般情况下，会有多个，直接以 “,” 相连即可。 超长省略处理，64 个字符。hover 超过 300ms 时，使用 tooltip 展示全部内容。	
Python 版本				
CUDA 版本				
镜像大小（GiB）	支持排序			
镜像地址		支持复制		
创建时间			直接展示时间，格式为：YYYY/MM/DD hh:mm:ss	

扩展：公共镜像需要扩展 2 个选填的字段，分别为是否包含模型文件、运行命令，这样的好处是，我们可以根据用户选择的镜像知道是否需要配置模型以及自动填充运行命令，包括公共模型和自定义模型（本次迭代无需考虑）。

2.2.4.2 公共镜像 - 列表搜索

参数	交互	说明
名称	输入框	模糊
框架	列表下拉	精确
Python 版本	列表下拉	精确
CUDA 版本	列表下拉	精确

框架、Python 版本、CUDA 版本是在列表的表头做下拉选的，交互效果（完整的交互效果请见金山云-云服务器-实例）类似下图：



结果展示：

+ 新建 开机 关机 重启 续费 更多 ▾					
检索项 实例状态: 运行中 重启中 ×					
☐	名称/ID ↕	镜像	监控	类型 ▾	状态 ▾
☐	gxq-axure 1c974b21-e67d-47f5...			星河云服务器	运行中

共 1 条

2.2.4.3 本次迭代提供哪些公共镜像

☒ 为本次提供

镜像名称	版本	备注
kohya_ss	☐ 1.2 ☐ 2.0 ☐ 2.1 ☐ 2.2	阿里云 t
modelscope-inference	☐ 1.8.1 ☐ 1.9.1	阿里云
chat-llm-webui	☐ 2.0 ☐ 2.1 ☐ 3.0 ☐ 3.0-blade ☐ 3.0-vllm	阿里云
tensorflow-serving	☐ 1.15.0 ☐ 2.11.1 ☐ 2.14.1	GPU 支持 阿里云
pytorch-inference	☒ 1.12	阿里云
tensorflow-inference	☐ 2.11	阿里云
python-inference	☐ 3.9	阿里云
chatbot-langchain	☐ 1.0	阿里云
tritonserver	☐ 23.08 ☐ 23.11	阿里云
stable-diffusion-webui	☐ 4.1 ☐ 4.2	阿里云
huggingface-inference	☐ 1.0	阿里云
llama-factory	☐ 0.1	阿里云
easyanimate	☐ 1.1.4 ☐ 1.1.5	阿里云
itag-udf	☐ 1.0	阿里云
chat-mllm-webui	☐ 1.0	阿里云

comfyui	☐ 1.6 ☐ 1.7	阿里云
pytorch1.8-cuda10.2-cudnn7-ubuntu18.04		华为云
mindspore1.7.0-cuda10.1-py3.7-ubuntu18.04		华为云
mindspore1.7.0-py3.7-ubuntu18.04		华为云
tensorflow2.1-cuda10.1-cudnn7-ubuntu18.04		华为云
pytorch1.10-cuda10.2-cudnn7-ubuntu18.04		华为云
conda3-ubuntu18.04		华为云
pytorch1.4-cuda10.1-cudnn7-ubuntu18.04		华为云
tensorflow1.13-cuda10.0-cudnn7-ubuntu18.04		华为云
conda3-cuda10.2-cudnn7-ubuntu18.04		华为云
spark2.4.5-ubuntu18.04		华为云
mindspore1.2.0-cuda10.1-cudnn7-ubuntu18.04		华为云
mindspore1.2.0-openmpi2.1.1-ubuntu18.04		华为云

3.API 需求说明

3.1 控制台 API

3.2 OpenAPI

4.监控需求说明

展示全部实例或者某个实例的性能监控指标：

指标	描述	单位	备注
QPS	每秒接收的请求数	1	
RT	平均响应时间	ms	
CPU Utilization	CPU 使用率	%	保留 1 位小数
Memory Usage	内存使用量	B（byte）	展示 B、KiB、MiB、GiB、TiB，进制 1024
GPU Utilization	GPU 使用率	%	保留 1 位小数
GPU Memery Usage	GPU 显存使用量	B（byte）	展示 B、KiB、MiB、GiB、TiB，进制 1024
TCP	TCP 连接数	1	

时间线	描述
近一小时（查询时间 - 一小时：查询时间）	时间横坐标间隔为 10min，时间描点颗粒为 10s
今天（00:00- 查询时间）	时间横坐标间隔为 4h，时间描点颗粒为 1min
昨天（00:00-23:59）	时间横坐标间隔为 4h，时间描点颗粒为 1min
近 7 天（以查询时间为当前时间，向前平移七天）	时间横坐标间隔为 2 天，时间描点颗粒为 5min
近 30 天（以当前查询时间为当前时间，向前平移 30 天）	时间横坐标间隔为 6 天，时间描点颗粒为 30min
自定义时间（最长时间为最近一个月）	时间横坐标间隔为选择时间 /6，时间描点颗粒为 30min

5. 计费需求说明

5.1 计费方式

按量付费（日峰值月结）

下单及退订方式：先下单，在创建资源；拉量计费。

产品线	边缘节点计算
产品类型	模型在线服务（Kenc-MOS/1143）
计费项	KENC-MOS
计费方式	日峰值月结
计费规则	按照模型在线服务所使用的实例规格、运行时长进行计费。
计费公式	模型在线服务的账单金额 = 服务实例规格单价 x 服务实例运行天数
价格因子	
单价	见 5.2 定价表
开始计费	模型服务实例创建成功后开始计费。
停止计费	模型服务实例非运行状态后停止计费。
注意事项	何为按量付费（日峰值月结） • 针对在使用的每种实例规格，每 5 分钟统计一次总数。 • 针对在使用的每种实例规格，每天最多可得到 288 个值。 • 取其中的最大值，作为当天对应实例规格的计费依据（用量）。 • 用户当天的费用等于所有实例规格乘以该实例规格用量最大值的加和（当天费用 =A 型号单价 * 当天 A 型号用量最大值 +B 型号单价 * 当天 B 型号用量最大值 +C 型号单价 * 当天 C 型号用量最大值 +...）。

5.2 定价表

实例规格	单价	备注
MOS.G1IN.2C8G	17.6 元 / 个 / 天	CPU 4 元 / 个 / 天 内存 1.2 元 / GB / 天
MOS.G1IN.4C16G	35.2 元 / 个 / 天	
MOS.G1IN.8C32G	70.4 元 / 个 / 天	
MOS.G1IN.16C64G	140.8 元 / 个 / 天	
MOS.N1IN.4C16G.1A9	204.2 元 / 个 / 天	Ada9 169 元 / 卡 / 天
MOS.N1IN.8C32G.2A9	408.4 元 / 个 / 天	
MOS.N1IN.16C64G.4A9	816.8 元 / 个 / 天	

附录 1：公共资源组规格列表

实例规格如何取名，请参考[附录 2：MOS 计算资源实例规格分类与说明](#)

实例规格 字符串	实例描述 字符串	类型 枚举类型，CPU 或 GPU	vCPU 整数，单位个	内存 整数，单位 GB	GPU 型号 字符串	GPU 显存 整数，单位 GB	GPU 数量 整数，单位个
MOS.G1IN.2C8G	2C8G	CPU	2	8			
MOS.G1IN.4C16G	4C16G	CPU	4	16			
MOS.G1IN.8C32G	8C32G	CPU	8	32			
MOS.G1IN.16C64G	16C64G	CPU	16	64			
MOS.N1IN.4C16G.1A9	4C16G 1*Ada9	GPU	4	16	GPU-Ada9	24	1
MOS.N1IN.8C32G.2A9	8C32G 2*Ada9	GPU	8	32	GPU-Ada9	24	2
MOS.N1IN.16C64G.4A9	16C64G 4*Ada9	GPU	16	64	GPU-Ada9	24	4

附录 2：MOS 计算资源实例规格分类与说明

第一组 产品代号	第二组 规格族			第三组 CPU 规格大小		第四组（可选） GPU 规格大小			
产品代号	规格族系列	规格族代数	规格族后缀	CPU 数量	内存 GB	GPU 卡数量	GPU 型号	独享 / 共享	共享显存 GB
MOS	G	4	IN	4	16	1	A9	V	16
均为大写字母 CPU 示例：MOS.G1IN.4C16G，GPU 示例：MOS.N1IN.4C16G.1A9/MOS.N1IN.4C16G.1A9V12G									
G 表示通用型，CPU: 内存=1:4； C 代表计算型，CPU: 内存=1:2； M 代表内存型，CPU: 内存=1:8； N 代表 GPU 通用型，CPU: 内存=1:4；		代数，从 1 开始	扩展位，可标识 Intel、AMD、华为等信息	数字 +C	数字 +G		A9 表示 RTX 4090	带 V 表示共享，不带 V 表示独享	数字 +G

6.运营需求说明

6.1 USS 系统计费项增加

无

6.2 出账单

无


6.3 权限

开通 MOS 时，搭配开通云主机、文件共享、容器权限。

- OMS 配置 @杨明颖
- 底层实现
 - oms @黄泽昆 23 号
 - 开通 MOS 产品权限，自动关联创建 MOS Harbor 账户并将对应的 ImagePullSecret 通过 wayne-apiserver 的接口添加 / 更新到 Namespace 的对应字段中。
 - wayne

- mysql @楚得允 20 号
 - Namespace 表扩展字段用于记录 MOS Harbor SecretMetadata。
- wayne-apiserver @楚得允 20 号
 - 扩展 Create/Update 接口用于支持 MOS Harbor SecretMetadata，添加 Namespace PATCH 接口用于单独更新指定字段。
- wayne-ui @李雨来 20 号
 - 后台 Namespace UI 添加 MOS Harbor SecretMetadata 适配，防止提交时覆盖。
- wayne-job @刘月 20 号
 - Namespace 检查项中添加 MOS Harbor ImagePullSecret 项，自动向开通权限的边缘节点创建 Namespace 拉取镜像的 Secret(名称可以设置为 mos-image-secret)。
- wayne-console @刘月 20 号
 - 创建 MOS 服务时设置 ImagePullSecret 的值为(4)中创建的 Secret 名称。

用户进入 mos 服务后，如果有权限，则可以正常显示相关的页面；如果没有权限，则显示如下页面：



六、深层次需求挖掘

可以为终端用户提供就近服务的经济算力。

七、资源

7.1 测试资源

7.2 生产资源

八、排期上线计划

尽可能列举出所有该需求相关的任务、明细、负责人、截止时间。后可同步至  [边缘计算事务管理](#)

目标上线时间为 xx 年 xx 月 xx 日。

项目阶段	节点	负责人	启动时间	完成时间	备注（输出物，文档可更新到该文档或者提供文档链接）
产品需求	立项材料	@王羲桀		11月7日	
	产品上线流程	@高现起		12月6日	 新产品立项评审-模型在线服务MOS
	内部需求沟通会	@朱岩		10月28日	
	外部需求沟通会	@高现起		10月30日	
	产品需求说明书	@高现起		11月18日	
	产品需求说明书和架构设计对齐	@高现起 @李雨来		11月19日	
	PRD 评审	@高现起		11月19日	
架构设计	整体架构设计	@李雨来		11月13日	 AI平台  AI PaaS功能模块划分
	详细架构设计	@李雨来		11月18日	 AI PaaS功能模块划分
	研发分工	@姚鑫 @朱岩		11月19日	 AI平台
API 文档	模型、镜像控制台 API 文档	@王奋逸		11月22日	
	服务相关 API 文档	@楚得允		11月29日	服务接口： http://10.160.61.129:8300/project/900/interface/api/cat_7716 服务实例接口： http://10.160.61.129:8300/project/900/interface/api/cat_7721
	监控 API 文档	@底雄飞		11月28日	

开发	模型分发模块	@姚鑫		11月29日	1. 对接KS3模型bucket。 2. 构建边缘模型缓存服务。
	模型部署模块	@李雨来		12月13日	1. 验证rclone下载文件夹完成。
	Docker 镜像服务	@贺飞		11月28日	1. 验证 & 完成 harbor proxy cache 搭建。
	公共镜像和公共模型	@贺飞		12月13日	1. 导入常用模型到ks3。 2. 构建多版本推理服务基础镜像。
	服务部署模块	@刘月		12月20日	
	API 网关模块	@楚得允		12月26日	
	监控数据采集	@底雄飞		12月6日	
	DNS 模块	@王奋逸		12月20日	1. KDNS 接口对接 (http://ezone.ksyun.com/wiki/cvc-data/page/892383992669622272) 2. 自建DNS (待定)
	模型、镜像控制台 API	@王奋逸		12月13日	1. 对接Harbor数据 (直通harbo数据或平台同步数据) 2. 镜像列表 (前台) + 镜像增删改 (后台) API 3. 对接文件共享服务 API 4. 镜像列表 (前台) + 镜像增删改 (后台) API 5. 导入功能
	服务相关 API	@楚得允		12月19日	

	计费开发	@黄泽昆		12月20日	
	MOS 服务工单	@高现起		12月20日	用于收集用户需求，例如公共镜像、公共模型、资源规模等
	前端开发	@王志嵩		12月20日	
联调测试	控制台联调	@楚得允 @王奋逸 @王志嵩	12月23日	12月27日	
	测试排期				
上线	底层上线			12月31日	
	控制台上线			12月31日	
	计费上线			12月31日	
	提上线单				
	上线				
文档	产品文档				
	OpenAPI 文档				
	售前 PPT				

九、模型使用方法

1.chatglm-3-6b

1.1 导入文件共享服务

例如导入到 /data/chatglm-3-6b/

1.2 部署服务时，模型服务相关配置

* 镜像

公共镜像自定义镜像

library/chatglm-inferencev1.0

没有我想要的? 告诉我们[立即前往](#)

模型配置

— 删除模型配置

* NFS

sfss-mm4wezdbmjrtmnbw-xmct41

没有我想要的? [立即前往](#)

* NFS 源路径

/data/chatglm-3-6b/

请确保模型文件已导入, 如果还没有导入模型文件? 可以在公共模型列表进行导入[立即前往](#)

* 挂载路径

/data/model/chatglm3-6b/

以读写的形式进行挂载

+ 添加模型配置(1/1)

* 运行命令

streamlit run basic_demo/web_demo_streamlit.py

镜像选择: library/chatglm-inference:v1.0

源路径输入: chatglm-3-6b/

挂载路径输入: /data/model/chatglm3-6b/

运行命令输入: streamlit run basic_demo/web_demo_streamlit.py

1.3 验证方式

1.3.1 web 验证方式

- 绑 host
 - 27.159.92.100 serviceame.mos.ksyun.com
- 浏览器访问
 - http://serviceame.mos.ksyun.com

1.3.2 命令行验证方式

- 使用服务实例进入容器功能
- 执行 `nvidia-smi` 命令

2.Meta-Llama-3-8B

2.1 导入文件共享服务

例如导入到 /data/Meta-Llama-3-8B/

2.2 部署模型服务

镜像选择：library/llama-inference:v1.0

源路径输入：Meta-Llama-3-8B/

挂载路径输入：/data/model/meta-llama/LLaMA-3-8B/

运行命令输入：python3 app.py

2.3 验证方式

1. 绑 host
27.159.92.100 serviceame.mos.ksyun.com
2. 使用 `curl` 命令调用推理服务 API

Bash

```
1 curl -X POST http://servicename.mos.ksyun.com/generate -H "Content-Type: application/json" -d '{"prompt": "Once upon a time", "max_length": 50}'
```