

模型在线服务 MOS v1.1 需求说明书

 产品名称为模型在线服务，Model Online Service，简称 MOS

-  是启发，不是限制。
- 是记录，不是条例。
- 懂业务，懂业务，懂业务，我们是第一个客户。
- 遇到问题或者有更好的想法，随时找高现起。

一、背景

首先，经历了大家一个多月的艰苦奋战，1.0 终于还是如期上线，在这里给大家点赞。同时，我们也知道，1.0 版本的目标是有个东西，是我们自己的一个玩物（所以也希望大家平时多用多想多提宝贵建议）。随着 1.0 的上线，接踵而来的任务就是马不停蹄的对它进行丰富，我们都知
道，1.0 版本不支持自定义，所以我们将 在 1.1 这个版本对它提升的主要能力就是支持自定义，支持自定义模型，支持自定义镜像。

1.0 版本的内容，请见  [模型在线服务MOS v1.0需求说明书](#)

二、目标

1.项目整体目标

- 整合分散算力：整合分散化、异构化 AI 算力，以满足推理场景的算力需求为主，为客户提供就近的经济算力。AI 算力平台，使客户像使用 CDN 一样使用 AI 算力。
- 开箱即用：客户不必关心资源在具体哪个节点，运行环境如何。最终给客户具备一定基础设施能力（如 DB、队列等）的算力平台。
- 灵活的售卖方式：提供灵活的售卖方式，包括：按大区划分算力供给。可在大区内进行算力调度。按小时的弹性能力和计费。

2.本次迭代

💡 以下所有内容，围绕本次迭代展开。

2.1 目标（要什么）

1.0 版本是有个东西，可以让我们后续的迭代看得见摸得着。

1.1 版本的目标是，初步可以允许客户上来进行测试，比如支持自定义镜像和自定义模型，另外要继续丰富公共镜像和公共模型的种类。

2.2 不要什么？

资源组。1.1 仍然不做资源组。

多区域部署。目前没有想清楚，所以先不做。

三、需求影响范围 & 方案（落地风险评估）

3.1 新功能

- sku 及库存管理
 - 价值：资源的确定性，选到的资源，就可以部署
- 自定义模型
 - 价值：满足企业个性化的需求
 - 导入的列表需要扩展一个字段，即显示公共模型和自定义模型
- 自定义镜像
 - 价值：满足企业个性化的需求
- 丰富公共模型和公共镜像
 - 价值：客户上来看的时候，怎么着也得像模像样，不能让客户感觉自己是小白鼠
 - Stable Disffusion 文生图 / 图生图
 - Llama 3.1-8b 大语言模型
 - Gemma-7B
 - Yi1.5-6B 大语言模型
 - Qwen2.5-7B 大语言模型
 - Baichuan2-7B

- Mixtral-7B
- DeepSeek 大语言模型
- Whisper 语音转文字
- LJ Speech 文字转语音

3.2 优化

- 部署服务页面，模型服务信息模块，增加端口号参数
 - 价值：部署必须
- ~~部署服务页面，当选择公共模型时，可以自动填充运行命令和端口号~~
 - ~~价值：提升测试客户体验~~
- 服务实例列表，进入容器操作增加准入条件及相应的提示信息
 - 价值：确定性，知其然，知其所以然
- 服务实例列表，支持删除操作
 - 价值：生命周期管理必备，1.0 临时去掉的功能
- 服务详情页面，资源信息模块，增加实例规格字段，同时支持更改操作
 - 价值：生命周期管理必备
- 部署服务页面，模型服务信息模块，增加环境变量参数
 - 价值：部署必须
- ~~服务及服务实例列表，失败的状态，可以展示失败的原因~~
 - ~~价值：优化用户体验~~
- 部署服务页面，模型服务信息模块，支持挂载多个模型
 - 价值：满足企业个性化的需求
- 错误信息的规范问题？
 - 项目还在早期，错误信息的规范越早做打算越好。
 - 包括规范和翻译。
- 一期演示反馈的一些优化点

四、专有名词 & 规划概述 & 竞品调研

1. 专有名词

无

2.规划概述

- 计算资源✔
- 公共模型✔
- 公共镜像✔
- 服务管理✔
- 服务实例管理✔
- 监控✔
- 日志✔
- 部署事件✔
- 支持 CPU 类型计算资源✔
- sku 及库存管理 ⌚
- 自定义模型 ⌚
- 自定义镜像 ⌚
- 部署时，需要增加端口 ⌚
- 修改实例规格 ⌚
- 如何规范错误信息？（1. 错误信息规范 2. 统计 4xx 错误信息，翻译，前端做 mapping）⌚
- 业务域名 ksymos.com ⌚
- 1.1 上线之后，项目每个人都需要找一个模型进行部署和并实现演示效果 ⌚
- 1.1 上线以后，面向公司产研提供一款效率应用@wangfenyi ⌚
- 多地域部署（服务组）
- 区域的逻辑
- 公共模型支持支持部署
- GPU 共享
- 数据集的管理
- 部署时，能否直接选模型和版本，包括公共模型和自定义模型
- 部署服务时，镜像支持直接输入镜像地址
- 扩容改为扩缩容？
- 模型存储服务
- sku 价格直接显示到列表
- 删除服务时，需要验证码确认

- 公共资源组 GPU 共享模式
- 模型在线服务产品计费项
- 弹性伸缩的能力
- **专属资源组（包年包月）**
- 在线调试
- 流量管理
- 支持 VPC
- 内网互通（不同计算资源之间的相互访问，举例 nginx 服务访问同集群的模型在线服务等）
- 按量付费（实时）
- 抢占实例
- 包年包月
- 闲忙时计费
- 服务及服务实例的监控告警
- **预置大模型推理服务（按 token 付费）**
- 制作 filebrowser 的镜像并完成利用 mos filebrowser 的镜像可视化管理文件共享服务的最佳实践文档
- http/https 自定义模型下载
- 直接从 ModelScope 导入

3.竞品调研

💡 阿里云的 EAS 仍然是我们的对标产品，大家多学习学习。

阿里云 人工智能平台 PAI 模型在线服务 (MOS)

腾讯云 TI-ONE 训练平台 模型服务 - 在线服务

五、功能需求

1.后台需求说明

无

2.控制台需求说明

2.1 交互原型

<http://61.130.29.197/#id=m72yt0&p=%E6%A6%82%E8%A7%88>

2.2 新功能

2.2.1 sku 及库存管理

sku 由原来的下拉框更改为列表，列表内容为：

- 展示实例规格
- 展示实例规格详情
- 展示可售卖节点信息，哪些节点可售卖
- 展示售罄的信息
- 单价，按小时的单价，本次希望可以做到小时级的计费

* 算力规格：

实例规格	GPU	GPU显存	CPU	内存	可售卖节点	单价
☒ MOS.N1IN.4C16G.1A9	1 * GPU-Ada9	1 * 24 GiB	4	16	<u>3个可用节点</u>	¥ 14.04 /小时
☐ MOS.N1IN.8C32G.2A9	2 * GPU-Ada9	2 * 24 GiB	8	32	<u>3个可用节点</u>	¥ 14.04 /小时
☐ MOS.N1IN.16C64G.4A9	4 * GPU-Ada9	4 * 24 GiB	16	24	<u>3个可用节点</u>	¥ 14.04 /小时
☐ MOS.N1IN.4C16G.1A9	1 * GPU-Ada9	1 * 24 GiB	32	64	<u>3个可用节点</u>	¥ 14.04 /小时
☐ MOS.N1IN.8C32G.2A9	2 * GPU-Ada9	2 * 24 GiB	4	32	<u>3个可用节点</u>	¥ 14.04 /小时
☐ MOS.N1IN.4C16G.1A9 售罄	4 * GPU-Ada9	4 * 24 GiB	8	16	<u>3个可用节点</u>	¥ 14.04 /小时
☐ MOS.N1IN.8C32G.2A9 售罄	1 * GPU-Ada9	1 * 24 GiB	16	32	<u>3个可用节点</u>	¥ 14.04 /小时

所选算力规格：MOS.N1IN.4C16G.1A9

注释：超过8条时，出现垂直滚动条，高度可以展示7.6条记录。

注意事项：

- 列表的记录是否可用，是否售罄，是针对当前节点说的（虽然页面上看似是多选，但目前仍然是只能选一个节点）；
- 如果判断当前节点是否售罄？如果可售卖节点里面，不包含当前节点，则展示售罄；
- 可售卖节点展示的信息是，如果当前节点售罄了，用户可以怎么解决？那么他看到可售卖节点消息之后，可手动切换至可用节点。

2.2.2 自定义模型

2.2.2.1 新建

参数分类	参数	是否必填	说明	备注
------	----	------	----	----

新增模型	模型名称	必填	模型名称长度限制为 127 个字符 用户命名空间唯一性校验	
	版本号	选填	默认 1.0.0，用户可修改	
	模型描述	选填	描述文字不超过 1024 个字符 提示信息：请输入模型的描述，将会在模型的详情进行展示	
	版本描述	选填	描述文字不超过 1024 个字符 提示信息：请输入模型版本的描述，将会在版本的列表进行展示，例如初始版本、标准版本等。	

	来源	必填	对象存储 • URL ◦ 必填 ◦ URL 校验 ◦ placeholder 提示为 “例如： https://bucket01.ks3-sz.ksyun.com/models/qwen2.5-7b/” ◦ span 提示为 “请输入对象存储桶及模型文件根目录的外网地址” • AccessKey ID • AccessKey Secret Git • URL ◦ 必填 ◦ URL 校验 ◦ placeholder 提示为 “例如：https://gitlab.com/group/repo.git” ◦ span 提示为 “请输入 Git 仓库的外网地址” • 代码分支 • 代码 Commit • Git 用户名 • 访问 Token Http/Https • URL ◦ 必填 ◦ URL 校验 ◦ span 提示为 “请输入模型文件根目录的外网地址” • 用户名 • 密码	
--	----	----	---	--

新增版本	模型名称	必填	下拉框，展示已有模型名称	
	版本号	必填		
	版本描述	选填	描述文字不超过 1024 个字符	
	来源	必填	对象存储 - URL - 必填 - URL 校验 - placeholder 提示为“例如： https://bucket01.ks3-sz.ksyun.com/models/qwen2.5-7b/” - span 提示为“请输入对象存储桶及模型文件根目录的外网地址” - AccessKey ID - AccessKey Secret Git - URL - 必填 - URL 校验 - placeholder 提示为“例如：https://gitlab.com/group/repo.git” - span 提示为“请输入 Git 仓库的外网地址” - 代码分支 - 代码 Commit - Git 用户名 - 访问 Token Http/Https - URL - 必填 - URL 校验 - span 提示为“请输入模型文件根目录的外网地址” - 用户名 - 密码	1.1 版本先只支持对象存储

2.2.2.2 列表

参数	是否支持排序	是否支持复制	是否支持编辑	说明	备注
名称				模型名称，点击名称，进入详情。	
最新版本					
下载数量				展示规则同公共模型下载数量。	
创建时间	支持排序				默认时间倒序，即最新创建在的在最上边。
更新时间	支持排序				

2.2.2.3 列表搜索

参数	交互	说明
名称	输入框	模糊

2.2.2.4 导入

可参考公共模型的导入。不同点：

- 展示自定义模型相关信息
- 需要指定自定义模型的版本，默认选中最新的版本
- 文件路径为 “\${模型名称}-\${版本号}/”

2.2.2.5 删除

是否支持批量	不支持批量	
准入条件	任何	
弹窗标题	删除	
操作对象的资源类型	自定义模型	
具体操作	删除	
风险提示信息	删除后数据无法恢复，请谨慎操作。	
风险级别	error	常用为 warning、error
针对本次操作，相关的对象信息	名称、最新版本、下载数量	

2.2.2.6 详情

参数	是否支持复制	支持编辑	说明
模型 ID	支持复制		
模型名称		支持编辑	小弹窗，点击确定按钮后保存即可。
最新版本			tag 形式
创建时间			详情的时间格式无需特殊处理
版本数量			
模型描述			需要做超长处理，在页面最小宽度下，更多内容显示 "...", hover 超过 300ms 后，tooltip 展示全部内容。

2.2.2.7 详情 - 新增版本

同新建新增版本，只是这里的模型是定值。

2.2.2.8 详情 - 删除

同自定义模型列表的删除。

2.2.2.9 详情 - 版本列表

罗列该自定义镜像下所有的版本信息。

参数	是否支持复制	说明	备注
名称			
版本描述		超长处理，默认展示 40 个字符（酌情处理即可），更多内容显示"... "，hover 超过 300ms 后，tooltip 展示全部内容。	
来源		枚举值，对象存储、Git、Http/Https	
模型地址	支持复制	超长处理，默认展示 64 个字符（酌情处理即可），更多内容显示"... "，hover 超过 300ms 后，tooltip 展示全部内容。	默认时间倒序，即最新创建在的在最上边。
创建时间		时间格式无需特殊处理	

2.2.2.10 详情 - 版本列表 - 删除

是否支持批量	不支持批量	
准入条件	任何	
弹窗标题	删除	
操作对象的资源类型	自定义模型版本	
具体操作	删除	
风险提示信息	删除后数据无法恢复，请谨慎操作。	
风险级别	error	常用为 warning、error
针对本次操作，相关的对象信息	版本、版本描述、来源	

2.2.2.11 导入历史

导入历史在原来的基础上需要扩展一个字段，模型类型字段，取值公共模型和自定义模型。

位置放在模型的后边或者以 tag 的形式和模型名称放一列，在名字的后边。

2.2.3 自定义镜像

2.2.3.1 开通服务（即初始化）

静态引导文案

欢迎使用自定义镜像

第一步 开通私有镜像仓库并设置初始密码

第二步 根据提示推送镜像

左侧图片素材用概览页的第二个或者第三个都可以的。

点击【立即开通】会弹窗展示设置镜像仓库密码。

参数	是否必填	说明
用户名		只读 提示信息： 当前登录控制台的用户名
密码	必填	密码复杂度要求： 长度 8-128，需包含至少 1 个大写字母、1 个小写字母和 1 个数字。 输入框下边的提示文案：长度 8-128，需包含至少 1 个大写字母、1 个小写字母和 1 个数字。 不符合直接提示 “不符合密码规则，请修改后重试。”
再次输入密码	必填	判断是否和密码相同，否则提示 “两次输入密码不一致”

如果使用 API 渲染自定义镜像页面？

如何判断是否开通服务？	http://10.160.61.129:8300/project/900/interface/api/42450 已开通： {"code":200,"message":"Project name exists"} 未开通： {"code":404,"message":"Project name does not exist"}
未开通服务	设置密码（用户名即为主账号用户名） http://10.160.61.129:8300/project/900/interface/api/42458 创建项目（项目名称为主账号 UID） http://10.160.61.129:8300/project/900/interface/api/42442
已开通服务	获取项目 ID http://10.160.61.129:8300/project/900/interface/api/42410 查看该项目的镜像列表 http://10.160.61.129:8300/project/900/interface/api/42418

2.2.3.2 推送镜像

弹窗展示静态内容。代码部分支持复制。

文案如下：

- 1. 登录容器引擎所在的机器
- 2. 执行以下命令进行登录（username 为登录控制台的用户名，password 为镜像仓库的密码）

Plain Text

```
1 docker login -u {username} -p {password} registry.mos.ksyun.com
```

3. 上传 / 下载镜像

Plain Text

```
1 sudo docker tag {镜像名称}:{版本名称} registry.mos.ksyun.com/{项目名称}/{镜像名称}:{版本名称}
2 sudo docker push registry.mos.ksyun.com/{项目名称}/{镜像名称}:{版本名称}
```

2.2.3.3 重置镜像仓库密码

内容同开通服务的弹窗，注意弹窗的标题为“重置镜像仓库密码”。

2.2.3.4 列表

参数	是否支持排序	是否支持复制	是否支持编辑	说明	备注
名称		支持复制		镜像名称，点击名称，进入详情。	
版本数量					
下载数量				展示规则同公共模型下载数量。	
创建时间	支持排序				默认时间倒序，即最新创建在的在最上边。
更新时间	支持排序				

2.2.3.5 列表搜索

参数	交互	说明
名称	输入框	模糊

2.2.3.6 详情

参数	是否支持排序	是否支持复制	说明	备注
标签		支持复制		
大小			单位为 KiB、MiB、GiB、TiB（进制为 1024）	
镜像地址		支持复制	超长处理，默认展示 64 个字符（酌情处理即可），更多内容显示"...", hover 超过 300ms 后，tooltip 展示全部内容。	
创建时间	支持排序		时间格式无需特殊处理	默认时间倒序，即最新创建在的最上边。

2.2.3.7 部署服务页面，支持选择自定义镜像

@江倩 @李雨来

* 镜像：

公共镜像

自定义镜像

llama 3

2.5

 [新建自定义镜像](#) 

获取项目 ID

<http://10.160.61.129:8300/project/900/interface/api/42410>

查看该项目的镜像列表（对应第一个下拉框）

<http://10.160.61.129:8300/project/900/interface/api/42418>

查看该镜像的版本列表（对应第二个下拉框）

<http://10.160.61.129:8300/project/900/interface/api/42434>

自定义镜像的回传入参为：[registry.mos.ksyun.com/\\${repo_name}:\\${tag_name}](https://registry.mos.ksyun.com/${repo_name}:${tag_name})，其中
\${repo_name}为 <http://10.160.61.129:8300/project/900/interface/api/42418> 的 name 字段，
\${tag_name}为 <http://10.160.61.129:8300/project/900/interface/api/42434> 的 name 字段。

交互：第一个下拉框，没有默认值，先加载第一个下拉框，placeholder 分别展示：“请选择自定义镜像”，“请选择镜像版本”；用户选择镜像后，再加载其版本信息，然后时间倒序，默认选中最新的版本。

点击【新建自定义镜像】文字链时，**新页**打开镜像列表页。

2.2.4 丰富公共模型和公共镜像

@贺飞

公共模型如下所示，先支持 ollama 的格式的模型：

- ~~Stable Disffusion~~文生图/图生图
- Llama 3.1-8b 大语言模型
- ~~Gemma-7B~~
- Yi1.5-6B 大语言模型
- Qwen2.5-32B 大语言模型
- ~~Baichuan2-7B~~
- ~~Mixtral-7B~~
- deepseek-ai/DeepSeek-R1-Distill-Qwen-32B
- Whisper 语言转文字
- ~~LJ Speech~~文字转语音

公共镜像围绕公共模型的使用展开，缺什么补什么，目标是让公共模型跑起来。

2.3 优化

2.3.1 部署服务页面，模型服务信息模块，增加端口号参数

@刘月 @楚得允 @江倩

位置	是否必填	说明
运行命令 下边	必填	数字输入框。 范围为 1 到 65535。 提示信息为：镜像启动后监听的本地 HTTP 端口，范围为 1~65535。

2.3.2 部署服务页面，当选择公共模型时，可以自动填充运行命令和端口号

公共模型需要扩展至少3个字段，第一个是运行命令，第二个是端口号，第三个提示文案。
是否环境变量是否需要？

2.3.3 部署服务页面，模型服务信息模块，增加环境变量参数

@刘月 @楚得允 @江倩

位置	是否必填	说明
端口号下边	必填	文本输入框。 每个输入框最多支持输入 128 个字符。 键值对，最多支持 20 对。 需要做非空校验。

2.3.4 部署服务页面，模型服务信息模块，支持挂载多个模型

@刘月 @贺飞 @江倩

最多支持挂载 3 个模型。

我记得 Stable Disffusion 是需要挂载多个模型的，可以问下贺飞，如果是的话，可以用 SD 来验证。

多个模型时，详情的模型配置字段如何展示？

详情服务实例监控日志部署事件

基础信息

服务名称gxq

调用信息调用信息

修改时间2025-01-08 15:16:10

服务域名gxq

创建时间2025-01-08 15:15:58

环境信息

镜像library/chatglm-inference:v1.0

启动命令streamlit run basic_demo/web_demo_streamlit.py

模型配置信息mount sfss-meytgmjwhe3ggodb-xmct41172.20.7.7:...

资源信息

资源组类型公共资源组（按量付费）

实例数量1

地域

实例数量

CPU(核数)

内存(GB)

GPU(卡数)

1. 原 “\${sfss_id}\${sfss_ip}” 改为 “\${sfss_name}\${sfss_ip}”
2. 多个模型以 “;” 间隔，复制或者 hover 展示所有内容。

2.3.5 服务实例列表，进入容器操作增加准入条件及相应的提示信息

@江倩

准入条件	运行中	不可用时的提示：运行中的服务实例支持该操作。 交互：hover 超过 300ms 后以 tooltip 的形式展示提示信息。
------	-----	---

2.3.6 服务实例列表，支持删除操作

@刘月 @江倩

1.0 版本由于时间及访问问题暂时去掉了，1.1 考虑加进来，以完善服务实例的生命周期管理。

2.3.7 服务详情页面，资源信息模块，增加实例规格字段，同时支持更改操作

@楚得允 @江倩

增加实例规格的展示。同时支持更改操作。

更改页面为抽屉弹窗的形式，展示的内容可以参考部署服务的算力规格的选择。

交互的注释：


- 1. 超过 8 条时，出现垂直滚动条，高度可以展示 7.6 条记录。
- 2. 如果列表的内容太宽，则出现水平滚动条，同时固定首列和尾列。

2.3.8 服务及服务实例列表，失败的状态，可以展示失败的原因

样式及交互请见原型的服务列表页下方。先直接展示错误信息的内容即可。

2.3.9 导入历史页面，状态只能依靠手动刷新，能否可以自己动


@李雨来 @王奋逸 @江倩



后端需要把更新频率提高，前端同学是否可以如果判断是正在导入，就每 5 秒钟刷新一下状态

2.3.10 部署服务时，点击【部署】按钮后，部署请求影响时间有点长

@楚得允 @刘月



2.3.11 服务域名不能用 mos.ksyun.com 的域名，需要申请新域名

@高现起

原因：假如某个用户使用 mos 生产出来的违禁内容，ksyun.com 会被封，风险很大，所以需要另外申请其他的域名，来生产 mos 的服务域名。

dnspod?

2.3.12 调用信息的弹窗，字段的展示形式需要改下，现在的像是一个输入框

@江倩




把输入框去掉，直接展示就行，就像底下的。复制的按钮也需要微调一下，跟在文本内容的后边，中间聚拢个 8px 就可以。

```
Linux 客户端挂载命令建议：  
sudo mount -t nfs -o rsize=1048576,wsz=1048576,hard,timeo=600,retrans=2 172.20.7.7:/data /data
```

2.3.13 文案修改

@江倩

💡 改文案的时候，最好全局搜一下哈，避免漏改情况



- 列表的表头（包括大列表和弹窗上的列表），将“资源组种类”改为“资源组”
- 扩容弹窗上的“实例数量”改为“扩容数量”
- 全局搜一下，将“公共资源组（按量付费）”改为“公共资源组”，之前描述不对
- 全局搜一下，将“专属资源组（包年包月）”改为“专属资源组”，之前描述不对
- 服务的操作，“扩容”改为“扩容服务”，“删除”改为“删除服务”
- 服务实例的操作，“删除”改为“删除实例”

2.3.14 对服务进行更新模型配置后，实例数量有点奇怪

@楚得允

比如现在有 2 个服务实例，理论上操作后，也会出现 2 个新的，但实际只会出现 1 个（状态为调度中，此时列表共 3 条记录），过一段时间，主动刷新一下之后，就变成 4 个了（状态为运行中），过一段时间，主动刷新一下，就又变成 2 个了。

2.3.15 更新模型配置后的动静有点大

@楚得允

更新操作后，列表会出现新旧共存，动静有点大。还会有一个风险，就是没有库存了，但是客户需要更新，这个时候就只能更新失败。

2.3.16 更新模型配置的交互可能需要变

@江倩

支持端口号、环境变量后，跟新模型配置的弹窗也需要随着变，可能弹窗的交互就不合适了。建议使用抽屉弹窗来承载，即可以不打断当前的任务，也可以很好的扩展操作区域。

2.3.17 部署服务页面，源路径可以由输入框改为可输入的下拉框

@王奋逸 @江倩

模型配置

删除模型配置

* NFS

sfss-gjrtenzmq4gmzbs-xmct41

▼

没有我想要的? [立即前往](#)

* NFS 源路径

/data/

待挂载的源文件路径

请确保模型文件已导入，如果还没有导入模型文件? 可以在公共模型列表进行导入[立即前往](#)

必须填写

* 挂载路径

输入挂载路径

以读写的形式进行挂载

+ 添加模型配置 (1/1)

* 运行命令


请输入运行命令

迭代替填

现在的使用门槛有点高。可以取导入历史中，该文件共享服务实例的、状态为导入成功的、同时顺序为时间倒排（即最新导入的记录在最上边）。

注意下拉框的内容需要去掉 “/data/” 。

改成下边这种样式的选择框，可输入可选择（这样即可以提升用户体验，同时也可以兼顾用户通过其他方式更改模型路径后无法选择和输入的问题）。



2.3.18 挂载路径，需要增加限制

@江倩

模型导入页面，包括公共模型和自定义模型。

导入

×

确定要对以下 **1个公共模型** 进行 **导入** 操作？

名称

chatglm-3-6b

* 文件共享服务

请选择

没有我想要的？[立即前往](#)

* 文件路径

/data/

chatglm-3-6b/

请输入模型文件所要放的路径

取消

确定

部署服务页面，包括更新模型配置。

模型配置

— 删除模型配置

* NFS

请选择

没有我想要的？[立即前往](#)

* NFS 源路径

/data/

待挂载的源文件路径

请确保模型文件已导入，如果还没有导入模型文件？可以在公共模型列表进行导入[立即前往](#)

* 挂载路径

输入挂载路径

以读写的方式进行挂载

必须填写

+ 添加模型配置 (1/1)

路径信息，需要手动输入的，需要增加合法性校验，允许 0~9、a~z、A~Z、/（斜杆）、\（反斜杆）、-（中横线）、_（下划线）、.（点）。注意，全部为英文状态的符号。不合法时，提示信息为“支持大小写字母、数字、-_/\。”

2.3.19 导入历史，增加文件共享服务实例名称的展示

@王奋逸 @江倩

导入历史

模型		导入至	状态	开始时间	完成时间
通义千问2.5-代...	公共模型	gxq-nfs /data/model	导入成功	2024/11/10 16:05:28	2024/11/10 16:11:01
OmniGen-v1	自定义模型	sfss-meytgjwhe3gg... /data/model	正在导入 (16%)	2024/11/10 15:30:31	2024/11/10 16:20:45

导入至列展示 2 行，一行取文件共享服务实例的名称，第二行取导入的目录。每行都做一下超长省略，hover 超过 300ms 后，tooltip 展示全部内容。不折行。

模型一列，增加标签样式的提示，显示公共模型和自定义模型。

2.3.20 列表列宽调整，使整体显示的紧凑一些，不折行，太长的话就做超长处理

@江倩

导入历史的列表：

模型	导入至	状态	开始时间	完成时间
chatglm-3-6b	/data/chatglm-3-6b/	导入成功	2025-01-03 18:02:02	2025-01-03 21:05:42
Meta-Llama-3-8B	/data/Meta-Llama-3-8B/	导入成功	2025-01-03 18:02:07	2025-01-03 21:08:52
chatglm-3-6b	/data/chatglm-3-6b/	导入成功	2025-01-06 17:42:03	2025-01-06 17:45:17



镜像的列表：




2.3.21 服务列表页右上角增加命名空间的下拉框，以解决管理员无法正常使用的问
题

@江倩

现在的逻辑是，进入页面之前会先请求用户的命名空间列表，普通用户一般只有一个，1.0 的时候临时的方案是取第一个为当前使用的命名空间，但是管理员名下会有很多命名空间，默认取第一个的情况下，用户是无法正常使用模型在线服务的（第一个命名空间未必具备相关的权限），所以当管理员登录时，右侧会出现一个命名空间的下拉框，显示选择一下就可以了。

结论：命名空间为一个时，不出现下拉框；命名空间为多个时，出现下拉框。



2.3.22 文件共享服务实例的选择，通过把样式改为 \${name}(\${id})

@江倩

价值：帮助用户更快识别并选择对应的文件共享服务。

注意：因为文件共享服务的 name 默认是以 id 填充的，所以默认情况下，两个都显示会比较长，需要做超长处理（这种情况再部署页面不会发生，在弹窗例如模型的导入会出现）。

公共模型的导入、自定义模型的导入、部署页面的 nfs 选择、更新模型配置的 nfs 选择，我能想到的是这 4 个地方，通过 API 的调用，看一下是否还存在其他的地方，也一并改下哈。

该建议有天意提出，给天意点赞。

2.3.23 服务的操作，由【扩容服务】改为【扩缩容服务】

@江倩 @楚得允

扩容

→ 扩缩容服务

确定要对以下 1个服务 进行 扩容 操作？

名称	资源组种类	实例数
gxq	公共资源组（按量付费）	2

* 地域

☒ 厦门电信41

去掉

* 实例数量

-

1

+

需要显示当前实例数量

可选实例数量范围为1~20，如果更多实例请 [提交工单](#) 申请。

取消

确定

- 改文案，把“扩容”改为“扩缩容服务”。
- 去地域，地域的字段就去掉了。未来服务创建好之后，地域就定了。
- 回显当前实例数，可加可减（即为扩缩容）。
- label “实例数量” 改为 “目标实例数量”。

3.API 需求说明

3.1 控制台 API

服务及服务实例控制台 API 由 @楚得允 来完成

镜像及模型的控制台 API 由 @王奋逸 来完成

3.2 OpenAPI

无（1.0 和 1.1 暂不提供 OpenAPI，待整体架构和功能稳定后，再重新梳理）

4. 监控需求说明

无

5. 计费需求说明

💡 本次迭代并没有更新计费相关的功能，仅仅是丰富了 sku 的种类。

5.1 计费方式

按量付费（日峰值月结）

下单及退订方式：先下单，在创建资源；拉量计费。

产品线	边缘节点计算
产品类型	模型在线服务（Kenc-MOS/1143）
计费项	KENC-MOS
计费方式	日峰值月结
计费规则	按照模型在线服务所使用的实例规格、运行时长进行计费。
计费公式	模型在线服务的账单金额 = 服务实例规格单价 x 服务实例运行天数
价格因子	
单价	见 5.2 定价表
开始计费	模型服务实例创建成功后开始计费。
停止计费	模型服务实例非运行状态后停止计费。
注意事项	何为按量付费（日峰值月结） - 针对在使用的每种实例规格，每 5 分钟统计一次总数。 - 针对在使用的每种实例规格，每天最多可得到 288 个值。 - 取其中的最大值，作为当天对应实例规格的计费依据（用量）。 - 用户当天的费用等于所有实例规格乘以该实例规格用量最大值的加和（当天费用 =A 型号单价 * 当天 A 型号用量最大值 +B 型号单价 * 当天 B 型号用量最大值 +C 型号单价 * 当天 C 型号用量最大值 +...）。

5.2 定价表

xxx.xxx.xxx 代表原有的 sku 相关信息

xxx.xxx.xxx 代表本次迭代新增的 sku 相关信息

实例规格	单价	备注
MOS.G1IN.2C8G	17.6元/个/天	CPU 4元/个/天 内存 1.2元/GB/天
MOS.G1IN.4C16G	35.2元/个/天	
MOS.G1IN.8C32G	70.4元/个/天	
MOS.G1IN.16C64G	140.8元/个/天	
MOS.N1IN.4C16G.1A9	204.2元/个/天	Ada9 169元/卡/天
MOS.N1IN.8C32G.2A9	408.4元/个/天	
MOS.N1IN.16C64G.4A9	816.8元/个/天	
MOS.C1IN.1C2G	6.4元/个/天	
MOS.C1IN.2C4G	12.8元/个/天	
MOS.C1IN.4C8G	25.6元/个/天	
MOS.C1IN.8C16G	51.2元/个/天	
MOS.C1IN.16C32G	102.4元/个/天	
MOS.M1IN.1C8G	13.6元/个/天	
MOS.M1IN.2C16G	27.2元/个/天	
MOS.M1IN.4C32G	54.4元/个/天	
MOS.M1IN.8C64G	108.8元/个/天	
MOS.NM1IN.4C32G.1A9	223.4元/个/天	
MOS.NM1IN.8C64G.2A9	446.8元/个/天	
MOS.NM1IN.16C128G.4A9	893.6元/个/天	
MOS.NM1IN.16C64G.1A9	309.8元/个/天	
MOS.NM1IN.32C128G.2A9	619.6元/个/天	
MOS.NM1IN.64C256G.4A9	1239.2元/个/天	

MOS.NM1IN.128C512G.8A9	2478.4元/个/天	
MOS.NM1IN.24C192G.1GM403	1002.4元/个/天	GM403 676元/卡/天
MOS.NM1IN.48C384G.2GM403	2004.8元/个/天	
MOS.NM1IN.96C768G.4GM403	4009.6元/个/天	
		外内部型号对应关系 H100-GM402 H800-GM401 A100-GM301 A100（40G）-GM301- A800-GM302 4090-GDP401 H20-GM403 H200-GM4024

附录 1：公共资源组规格列表

实例规格如何取名，请参考[附录 2：MOS 计算资源实例规格分类与说明](#)

xxx.xxx.xxx 代表原有的 sku 相关信息

xxx.xxx.xxx 代表本次迭代新增的 sku 相关信息

实例规格 字符串	实例描述 字符串	类型 枚举类型，CPU 或 GPU	vCPU 整数，单位个	内存 整数，单位 GB	GPU 型号 字符串	GPU 显存 整数，单位 GB	GPU 数量 整数，单位个
MOS.G1IN.2C8G	2C8G	CPU	2	8			
MOS.G1IN.4C16G	4C16G	CPU	4	16			
MOS.G1IN.8C32G	8C32G	CPU	8	32			
MOS.G1IN.16C64G	16C64G	CPU	16	64			
MOS.N1IN.4C16G.1A9	4C16G 1*Ada9	GPU	4	16	GPU-Ada9	24	1
MOS.N1IN.8C32G.2A9	8C32G 2*Ada9	GPU	8	32	GPU-Ada9	24	2
MOS.N1IN.16C64G.4A9	16C64G 4*Ada9	GPU	16	64	GPU-Ada9	24	4
MOS.C1IN.1C2G	1C2G	CPU	1	2			
MOS.C1IN.2C4G	2C4G	CPU	2	4			
MOS.C1IN.4C8G	4C8G	CPU	4	8			
MOS.C1IN.8C16G	8C16G	CPU	8	16			
MOS.C1IN.16C32G	16C32G	CPU	16	32			
MOS.M1IN.1C8G	1C8G	CPU	1	8			
MOS.M1IN.2C16G	2C16G	CPU	2	16			
MOS.M1IN.4C32G	4C32G	CPU	4	32			
MOS.M1IN.8C64G	8C64G	CPU	8	64			
MOS.NM1IN.4C32G.1A9	4C32G 1*Ada9	GPU	4	32	GPU-Ada9	24	1
MOS.NM1IN.8C64G.2A9	8C64G 2*Ada9	GPU	8	64	GPU-Ada9	24	2
MOS.NM1IN.16C128G.4A9	16C128G 4*Ada9	GPU	16	128	GPU-Ada9	24	4
MOS.NM1IN.16C64G.1A9	16C64G 1*Ada9	GPU	16	64	GPU-Ada9	24	1
MOS.NM1IN.32C128G.2A9	32C128G 2*Ada9	GPU	32	128	GPU-Ada9	24	2
MOS.NM1IN.64C256G.4A9	64C256G 4*Ada9	GPU	64	256	GPU-Ada9	24	4

MOS.NM1IN.128C512G.8A9	128C512G 8*Ada9	GPU	128	512	GPU-Ada9	24	8
MOS.NM1IN.24C192G.1GM403	24C192G 1*GM403	GPU	24	192	GPU-GM403	96	1
MOS.NM1IN.48C384G.2GM403	48C384G 2*GM403	GPU	48	384	GPU-GM403	96	2
MOS.NM1IN.96C768G.4GM403	96C768G 4*GM403	GPU	96	768	GPU-GM403	96	4

附录 2：MOS 计算资源实例规格分类与说明

第一组 产品代号	第二组 规格族			第三组 CPU 规格大小		第四组（可选） GPU 规格大小			
产品代号	规格族系列	规格族代数	规格族后缀	CPU 数量	内存 GB	GPU 卡数量	GPU 型号	独享 / 共享	共享显存 GB
MOS	G	4	IN	4	16	1	A9	V	16
均为大写字母									
CPU 示例：MOS.G1IN.4C16G，GPU 示例：MOS.N1IN.4C16G.1A9/MOS.N1IN.4C16G.1A9V12G									
G 表示通用型，CPU: 内存=1:4； C 代表计算型，CPU: 内存=1:2； M 代表内存型，CPU: 内存=1:8； N 代表 GPU 通用型，CPU: 内存=1:4； NM 代表 GPU 内存型，CPU: 内存=1:8；		代数，从 1 开始	扩展位，可标识 Intel、AMD、华为等信息	数字 +C	数字 +G		A9 表示 RTX 4090	带 V 表示共享，不带 V 表示独享	数字 +G

6.运营需求说明

6.1 USS 系统计费项增加

不确定，请 @杨明颖 评估一下。

6.2 出账单

本次会加上删除服务实例和更改实例规格的操作，除此之外，不确定还有其他的工作涉及到账单开发的部分，请 @黄泽昆 评估一下。

6.3 权限

6.3.1 概述

开通 MOS 时，搭配开通边缘云主机、文件共享服务、边缘容器的权限。

6.3.2 客户侧的申请流程

@高现起

6.3.3 内部的开通流程

如何开通模型在线服务？在哪里开通？如何操作？谁能操作？

如何开通节点权限？在哪里开通？如何操作？谁能操作？

为什么管理员无法正常使用 MOS 服务，如何优化？在右上角加一个下拉框。

除次之外，本次迭代过程中，需要梳理出客户开通模型在线服务的流程以及内部的操作流程（包括权限和配额）。@高现起

顺便捎带一下，看看最近上线的文件共享服务、转码卡、GPU 共享是否需要增加配置？

如何开通文件共享服务？在哪里开通？如何操作？谁能操作？

如何为文件共享服务开通节点？在哪里开通？如何操作？谁能操作？

六、专项周例会记录

📖 模型在线服务MOS专项周例会记录

七、资源信息

7.1 测试资源

嘉兴多线 35（测试资源有限，测试完请及时删除）

如何访问模型在线服务 MOS 的测试环境？请访问  [模型在线服务测试环境访问指南](#) ；

7.2 生产资源

厦门电信 41

7.3 MOS 大模型部署实践

 [MOS大模型部署实践](#)

7.4 产品验收及反馈

 [产品验收记录及反馈](#)

7.5 测试验收及反馈

[@李天意](#) 请天意把测试的结果附在这里，建议把 xmind 转成在线的思维导图

测试结果：<https://boardmix.cn/app/editor/QISMg0XT3kmKaHyvpFgOtg>

八、排期上线计划

尽可能列举出所有该需求相关的任务、明细、负责人、截止时间。后可同步至  [边缘计算事务管理](#)

目标：2025 年 2 月 27 日（周四）上线。

项目阶段	节点	负责人	启动时间	完成时间	备注（输出物，文档可更新到该文档或者提供文档链接）
产品需求	产品需求说明书	@高现起	12月30日	1月3日	
	PRD 评审	@高现起	1月6日	1月8日	
研发分工	后端研发分工	@姚鑫	1月8日	1月9日	
	计费账单分工	@冯新国	1月8日	1月9日	
API 文档	服务部署和管理	@楚得允	1月9日	1月10日	已更新： http://10.160.61.129:8300/project/900/interface/api/cat_7716
	模型导入和管理	@王奋逸	1月10日	1月10日	
	自定义镜像管理	@李雨来	1月10日	1月10日	已更新： http://10.160.61.129:8300/project/900/interface/api/cat_7696

开发	服务部署和管理-API 接口	@楚得允	1月13日	1月21日	
	服务部署和管理-底层 实现	@刘月	1月13日	1月24日 2月14日	1月24日前完成基础的服务模块； 2月14日前完成指定实例名称 删除的第三方插件功能验证
	模型导入和管理-API 接口	@王奋逸	1月13日	1月15日	
	模型导入和管理-底层 实现	@李雨来	1月13日	1月21日	
	容器 GPU 可用资源同 步 CRD	@贺飞	1月13日	1月24日	
	丰富公共模型和公共 镜像	@贺飞	1月13日	1月24日	
	前端开发	@江倩	1月10日	1月23日	
	申请新服务域名	@高现起	1月13日	1月17日	
	外部客户权限申请以 及内部权限开通流程 梳理	@高现起	1月13日	1月17日	
	管理员无法登录问题 解决	@高现起	1月20日	1月24日	
	拉量接口变更	@刘静怡	1月13日	1月16日	
	订单处理	@黄泽昆	1月3日	1月10日	下单无影响
联调测试	控制台联调	@楚得允 @王奋逸 @江倩	2月5日	2月14日	
	测试	@李天意	2月15日	2月20日	
	修 bug	@江倩 @王奋逸 @楚得允	2月20日	2月26日	

上线	底层上线单	@姚鑫	2月26日	2月27日	
	控制台上线单	@江倩	2月26日		
	计费上线单	@黄泽昆	2月26日		
	运维上线	@徐磊	2月27日		
文档	产品文档				
	OpenAPI文档				
	售前PPT				

的外网地址